

TUGAS REVIEW PAPER

1. Firda Amallia Trisnawati (5003231006)
2. Camelia Cahya (5003231024)
3. Naqya Sakinah (5003231036)
4. Fahmadina Sophia (5003231122)
5. Faiz Nabilianto (5003231143)

Roadmap yang dipilih adalah *Large Language Model* pada Pusat Studi Kecerdasan Artifisial dan Teknologi Digital.

No.	Judul Artikel	Nama Jurnal	Indeks Scopus
1.	Building an effective chatbot for optimizing the debt collection process through large language models	Journal of Big Data	Q1
2.	Generating reliable software project task flows using large language models through prompt engineering and robust evaluation	Scientific Reports	Q1
3.	Large language model based machine translation for universal multilingual understanding and translation quality enhancement	Discover Computing	Q2
4.	Automating customer feedback analysis in E-commerce: A multi-Model approach	Expert Systems with Applications	Q1
5.	High Entropy Alloys Database generated with Large Language Model	Scientific Data	Q1

Jurnal 1

a. Latar Belakang

Perkembangan teknologi, seperti *artificial intelligence* (AI), khususnya *large language models* (LLM), mendorong terjadinya transformasi di berbagai sektor, termasuk bidang keuangan. Salah satu implementasi AI yang semakin berkembang adalah

penggunaan *chatbot* yang dimanfaatkan sebagai sarana penyampaian informasi dari perusahaan ke pelanggan secara otomatis. Pada awalnya, *chatbot* masih menghasilkan respons terbatas berdasarkan template yang telah ditentukan (*rule-based*). Namun, seiring perkembangan teknologi, *chatbot* berbasis *machine learning* dan *deep learning* mampu memahami bahasa alami secara lebih baik, sehingga dapat memberikan respons yang lebih fleksibel dan kontekstual dalam interaksi dengan pengguna. Dalam proses penagihan utang, metode tradisional seperti analisis risiko kredit dan prediksi keterlambatan pembayaran masih memiliki keterbatasan dalam menangani interaksi dinamis dengan pelanggan. Oleh karena itu, dikembangkan sebuah *chatbot* berbasis LLM untuk mengirimkan pengingat pembayaran otomatis, memberikan rekomendasi solusi pembayaran, serta mengklasifikasikan tingkat risiko pelanggan menggunakan metode *Deep Reinforcement Learning*.

b. Permasalahan

Ada empat pertanyaan utama yang ingin dijawab dalam penelitian ini:

1. Apakah metode *Deep Reinforcement Learning* mampu memberikan akurasi klasifikasi risiko pelanggan yang lebih tinggi dibandingkan algoritma yang sudah ada?
2. Apakah *chatbot* berbasis *Large Language Models* memiliki performa yang lebih baik dibandingkan *chatbot* konvensional berdasarkan nilai BLEU dan ROUGE?
3. Apakah teknik *fine-tuning* LoRa lebih efektif dalam mengurangi respons yang tidak relevan dibandingkan QLoRa?
4. Apakah terdapat perbedaan performa antara *chatbot* yang menggunakan GPT-3.5 dan Llama 2?

c. Metode/Teori

Penelitian ini menggunakan pendekatan yang menggabungkan *Deep Reinforcement Learning* (DRL), *Large Language Model* (LLM), serta teknik prompt engineering dan fine-tuning untuk membangun *chatbot* yang optimal dalam proses debt collection. Pertama, dalam tahap klasifikasi risiko pelanggan, peneliti menggunakan *Deep Reinforcement Learning* dengan *framework* Actor-Critic, yakni mengklasifikasikan pelanggan ke dalam 5 profil risiko: Very Low Risk, Low Risk, Medium Risk, High Risk, dan Very High Risk. Dalam hal ini, setiap pelanggan direpresentasikan sebagai *state* yang terdiri dari berbagai fitur seperti usia, pekerjaan, pendapatan, riwayat pembayaran, dan jumlah tunggakan. Model terus dilatih melalui mekanisme *reward*, di mana klasifikasi yang benar diberi nilai positif (+1) dan kesalahan diberi penalti (-1).

Selanjutnya, hasil klasifikasi risiko tersebut digunakan sebagai input dalam sistem *chatbot* berbasis *Large Language Model*, yaitu GPT-3.5 dan LLaMA 2 untuk menghasilkan respons percakapan yang natural dan kontekstual kepada pelanggan dalam proses penagihan utang. Berbeda dengan *chatbot* konvensional, LLM tidak bergantung pada aturan tetap (*rule-based*), melainkan mampu memahami konteks dan menghasilkan

respons yang dinamis. Untuk mengoptimalkan performa LLM, digunakan teknik prompt engineering. Peneliti menerapkan beberapa strategi, yaitu *zero-shot prompting*, di mana model menghasilkan respons tanpa contoh sebelumnya, *few-shot* atau *multi-shot prompting*, dengan memberikan beberapa contoh dialog, *chain-of-thought prompting*, yang membantu model dalam melakukan penalaran secara bertahap. Namun, LLM memiliki kelemahan berupa munculnya *hallucination* (respon tidak relevan atau tidak akurat). Untuk mengatasi hal ini, penelitian menerapkan *Parameter Efficient Fine-Tuning* (PEFT), khususnya menggunakan metode LoRA (*Low-Rank Adaptation*). Teknik ini memungkinkan model untuk disesuaikan dengan domain spesifik (*debt collection*) tanpa harus melatih ulang seluruh parameter model yang sangat besar. LoRA bekerja dengan memodifikasi sebagian kecil parameter menggunakan matriks ber-rank rendah, sehingga lebih efisien dari segi komputasi dan memori. Untuk mengevaluasi performa model, digunakan beberapa metrik evaluasi, di antaranya BLEU untuk mengukur kesamaan teks secara presisi; ROUGE untuk menilai cakupan informasi; METEOR untuk mempertimbangkan sinonim dan struktur kalimat; Accuracy, Precision, Recall, dan F1-score untuk evaluasi klasifikasi risiko

d. Kesimpulan

Menjawab keempat pertanyaan penelitian di poin b, dapat disimpulkan bahwa :

1. Penggunaan *Deep Reinforcement Learning* (DRL) terbukti efektif dalam meningkatkan akurasi klasifikasi risiko pelanggan sekitar 4,35% dari model sebelumnya sehingga mampu mencapai tingkat akurasi hingga sekitar 99%. Hal tersebut juga diperkuat oleh uji T yang memberikan nilai $p\text{-value} = 0,0041 < 0,05$ yang artinya framework DRL yang diusulkan terbukti secara statistik memberikan akurasi klasifikasi yang lebih tinggi dibandingkan algoritma yang ada.
2. Implementasi chatbot berbasis *Large Language Model* memberikan performa yang lebih baik dengan peningkatan 61,39% pada skor BLEU dan 129% pada skor ROUGE dibandingkan chatbot yang ada dalam literatur. Pada dataset chatbot dari Kaggle, perbedaan tidak signifikan secara statistik, tetapi chatbot berbasis LLM memberikan hasil signifikan lebih baik pada dataset Daily Dialog.
3. Penerapan teknik Parameter Efficient Fine-Tuning (LoRA) berhasil mengatasi permasalahan utama pada LLM, yaitu *hallucination* dengan meningkatkan 187% pada skor BLEU dan 25% pada skor ROUGE dibandingkan sebelum *fine-tuning*. Selain itu, $p\text{-value}$ pada uji T sebesar 0,0007 ($< 0,05$) juga menunjukkan kualitas LoRA yang lebih efisien dibandingkan QLoRA.
4. Hasil pengujian statistik menunjukkan bahwa tidak terdapat perbedaan signifikan antara performa chatbot berbasis GPT-3.5 dan LLaMA 2. Hasil tersebut diuji dengan *zero-shot prompting* memberikan $p\text{-value}$ sebesar 0,4361 ($> 0,05$) dan *multiple-shot prompting* memberikan $p\text{-value}$ sebesar 0,0846 ($> 0,05$). Hal ini menunjukkan bahwa kedua model memiliki kemampuan yang relatif setara..

Jurnal 2

a. Latar Belakang

Dalam dunia pengembangan perangkat lunak, salah satu tantangan yang cukup sering dihadapi adalah bagaimana mengubah dokumentasi proyek yang tidak terstruktur seperti README, wiki, atau blog menjadi *task flow* yang rapi dan berurutan. *Task flow* ini sangat penting karena digunakan untuk mengatur alokasi sumber daya, jadwal pengerjaan, hingga menghindari miskomunikasi antar anggota tim. Kehadiran Large Language Models (LLM) seperti GPT-4, Gemini, LLaMA, dan Grok membuka peluang besar untuk mengotomatisasi proses ini. Tapi masalahnya, *output* yang dihasilkan LLM sering kali tidak bisa sepenuhnya diandalkan karena metrik evaluasi yang selama ini dipakai seperti BERTScore, SBERT, dan Universal Sentence Encoder (USE) hanya mengukur kemiripan teks secara permukaan, tanpa benar-benar mengecek apakah urutan tugas yang dihasilkan sudah logis dan sesuai. Dari sinilah muncul kebutuhan untuk mengembangkan *framework* evaluasi yang lebih baik dan lebih sesuai dengan kebutuhan rekayasa perangkat lunak.

b. Permasalahan

Ada empat pertanyaan utama yang ingin dijawab dalam penelitian ini:

1. Apakah LLM mampu menghasilkan task flow yang andal dari dokumentasi proyek yang tidak terstruktur?
2. Seberapa besar pengaruh strategi *prompting* yang berbeda seperti Zero-Shot, Few-Shot, Chain-of-Thought, Role-Based, dan ISO 21502-Guided terhadap kualitas *task flow* yang dihasilkan?
3. Apakah metrik evaluasi yang sudah ada seperti BERTScore, SBERT, dan USE sudah cukup untuk mengukur kualitas task flow secara prosedural?
4. Apakah dapat dikembangkan metrik evaluasi baru yang lebih stabil dan mampu menangkap konsistensi urutan tugas secara lebih akurat?

c. Metode/Teori

Penelitian ini menggunakan pipeline multi-tahap untuk menguji kemampuan LLM dalam menghasilkan *task flow* yang andal, dengan tahapan sebagai berikut:

1. Persiapan Data dan Gold-Standard

Peneliti menggunakan lima proyek dari repositori *Build Your Own X* (Ray Tracing Engine, Blockchain, Neural Network, Operating System, Web Server) sebagai data uji. Dokumentasi diringkas menjadi 512 token menggunakan LLaMA 4 Scout, kemudian dikonversi menjadi task flow gold-standard dalam format JSON (judul, deskripsi, durasi).

2. *Framework Prompting*

Peneliti menerapkan lima strategi prompting, yaitu Zero-Shot, Few-Shot (3 contoh), Chain-of-Thought, Role-Based, dan ISO 21502-Guided (generate-evaluate-regenerate).

3. Konfigurasi LLM

Peneliti menggunakan lima model (Gemini 2.5 Pro, Grok 3, GPT-Omni, DeepSeek-R1, LLaMA-3 70B) dengan parameter yang disamakan semua, yaitu $temperature = 0$, $top-k = 50$, dan $top-p = 0.95$.

4. Pengaturan Eksperimen

Peneliti menjalankan eksperimen di Google Colab (GPU + API). Jika output tidak valid dalam format JSON, sistem melakukan *retry* hingga 3 kali.

5. Pencarian Bobot Optimal

Peneliti melakukan *randomized grid search* sebanyak 5.000 iterasi dengan *5-fold cross-validation* pada 50 data, dan memperoleh skor optimal HSSM sebesar 0.97.

6. Pengolahan Output dan Analisis Semantik

Peneliti melakukan beberapa tahap pemrosesan, yaitu penggabungan judul–deskripsi, ekstraksi key-term (LLM + BERT/RoBERTa), pemberian bobot linguistik (kata kerja 0.35, kata benda 0.20, kata sifat 0.15, dependensi 0.15, entitas bernama 0.40), serta normalisasi dengan clip maksimum 3.0.

7. Evaluasi dan Pengukuran Metrik

Pada tahap akhir, kualitas task flow dievaluasi menggunakan empat metrik sekaligus. BERTScore, SBERT, dan USE digunakan sebagai baseline pembanding, sementara HSSM menjadi metrik utama yang diusulkan. HSSM sendiri menggabungkan dua komponen, yaitu BaseSim yang merupakan rata-rata tertimbang cosine similarity dari empat model SentenceTransformer (MPNet bobot 0.35, Multilingual MPNet 0.25, MiniLM 0.20, DistilRoBERTa 0.20), dan ContextScore yang merupakan Jaccard overlap antara key-term task flow AI dengan task flow buatan manusia. Keduanya digabungkan dengan rumus:

$$HSSM = \min(0.80 \times BaseSim + 0.20 \times ContextScore, 1.0)$$

Skor dinormalisasi dengan sigmoid ($k = 15$).

Peneliti juga menggunakan uji statistik *Coefficient of Variation (CV)*, *Z-score*, *Pearson Correlation*, dan *Friedman Test*

d. Kesimpulan

Menjawab keempat pertanyaan penelitian di poin b, dapat disimpulkan bahwa:

1. LLM terbukti mampu menghasilkan *task flow* yang andal, dengan skor HSSM berkisar antara 90.76% hingga 96.33% di seluruh kombinasi model dan strategi *prompting*, membuktikan bahwa LLM dapat diandalkan untuk perencanaan proyek perangkat lunak berbasis AI.
2. Strategi *prompting* berpengaruh signifikan terhadap kualitas output. Secara mengejutkan, Zero-Shot menghasilkan skor HSSM tertinggi (96.33%), diikuti Few-Shot (95.23%), ISO Guided (94.29%), Chain-of-Thought (93.05%), dan Role-Based terendah (90.76%). Hal ini menantang asumsi umum dalam literatur bahwa Chain-of-Thought selalu unggul.

3. Metrik yang sudah ada sebelumnya terbukti tidak memadai. SBERT menunjukkan variansi sangat tinggi (CV mencapai 18.97%), USE rentan terhadap efek saturasi, dan BERTScore terlalu toleran terhadap kemiripan leksikal tanpa mempertimbangkan urutan prosedural.
4. HSSM berhasil dikembangkan dan divalidasi sebagai metrik yang lebih unggul, dengan CV hanya 1.5% hingga 2.9% di seluruh model yang diuji, korelasi Pearson tertinggi dengan penilaian manusia (0.88), dan sensitivitas yang terkontrol terhadap perubahan strategi *prompting*. Sehingga, hal ini dapat menjadikan HSSM sebagai alat evaluasi yang lebih reliabel untuk *task flow* yang terstruktur.

Jurnal 3

a. Latar Belakang

Komunikasi global saat ini sangat bergantung kepada kemampuan penenerjemahan bahasa secara otomatis. Dimana sejarah machine translation (MT) telah melewati beberapa fase perkembangan panjang sejak 1933, mulai dari Rule-Based Machine Translation (RBMT) yang mengandalkan kamus dan aturan gramatikal, kemudian Statistical Machine Translation (SMT) yang berbasis statistik dan data paralel, lalu Neural Machine Translation (NMT) yang menggunakan arsitektur encoder-decoder dengan mekanisme attention, hingga akhirnya era Large Language Models (LLM) yang dimulai sejak kemunculan BERT dan GPT pada 2018. Namun terdapat kelemahan dari NMT yaitu keterbatasannya dalam pemahaman kontekstual dan kesulitan menangani bahasa dengan sumber daya rendah (low-resource languages) mendorong munculnya pendekatan berbasis LLM. Model-model seperti GPT-3, GPT-4, PaLM, BLOOM, dan LLaMA dilatih dengan data masif multibahasa sehingga mampu menghasilkan terjemahan yang lebih alami, akurat, dan kontekstual.

b. Permasalahan

Terdapat 3 permasalahan utama yang diangkat ada dalam paper ini:

1. Apakah penggunaan LLM dalam machine translation dapat meningkatkan ketepatan dalam penerjemahan dan kelancaran terjemahan?
2. Bagaimana LLM menangani ambiguitas dalam machine translation, baik ambiguitas leksikal, struktural, maupun morfologis?
3. Apakah peningkatan performa LLM dapat mendorong kemajuan Multi-Modal Machine Translation (MMT) yang mengintegrasikan teks dan visual?

c. Metode/Teori

Penelitian ini merupakan systematic survey review yang tidak melakukan eksperimen baru, melainkan mengumpulkan, menganalisis, dan mensintesis temuan dari berbagai studi sebelumnya. Pengumpulan literatur dilakukan dari beberapa database akademik terkemuka, yaitu IEEE Xplore, ACM Digital Library, ScienceDirect, Springer,

Scopus, dan Web of Science, dengan rentang tahun 2018 hingga 2024. Pencarian menggunakan kombinasi kata kunci seperti *"large language models," "machine translation," "ambiguity resolution," "multimodal translation,"* dan *"translation adequacy."* Studi yang diinklusi mencakup penelitian yang mengevaluasi LLM-based MT menggunakan metrik standar, membahas adequacy dan fluency, menggunakan input multimodal, serta membandingkan model-model populer seperti GPT, LLaMA, PaLM, mBART, NLLB, dan BLOOM.

Dari sisi teknik dalam paper ini membahas dua pendekatan utama dalam mengoptimalkan LLM untuk machine translation, yaitu prompt engineering dan fine-tuning. Pada pendekatan prompt engineering, terdapat beberapa paradigma yang dibahas. Zero-shot prompting mengarahkan model untuk menerjemahkan tanpa contoh apapun dan cocok untuk bahasa dengan sumber daya tinggi, namun rentan terhadap kata-kata polisemous. Few-shot prompting memberikan beberapa contoh terjemahan dalam prompt untuk membantu model memahami konteks dan mengurangi kesalahan semantik. Task-specific prompting dan domain-specific prompting dirancang untuk memastikan akurasi terminologi dalam bidang-bidang khusus seperti medis, hukum, dan teknologi. Selain itu, Chain-of-Thought (CoT) prompting mendorong model untuk bernalar secara bertahap sebelum menghasilkan terjemahan, meskipun penelitian terbaru menunjukkan CoT dapat justru memperburuk kualitas terjemahan pada skenario zero-shot tertentu.

Pada pendekatan fine-tuning, penelitian ini mengkaji beberapa strategi yang lebih mendalam. Language-aware instruction tuning melatih model dengan instruksi multibahasa yang beragam agar mampu mengikuti instruksi terjemahan dengan lebih baik. Domain-Adaptive Fine-Tuning (DAFT) menggunakan korpus paralel domain spesifik untuk meningkatkan konsistensi terminologi. Parameter Efficient Fine-Tuning (PEFT) seperti LoRA dan QLoRA memungkinkan fine-tuning model berukuran besar secara efisien hanya dengan memperbarui sebagian kecil parameter, sehingga lebih hemat komputasi dan cocok untuk setting dengan sumber daya terbatas.

Untuk evaluasi performa terjemahan, paper ini mengkaji berbagai metrik yang umum digunakan. BLEU merupakan metrik paling populer yang mengukur kemiripan n-gram antara hasil terjemahan mesin dengan referensi, namun memiliki kelemahan dalam menangkap makna semantik dan sinonim. METEOR mengatasinya dengan mempertimbangkan sinonim dan stemming meskipun lebih lambat secara komputasi. TER mengukur jumlah edit yang dibutuhkan untuk menyesuaikan hasil terjemahan dengan referensi. COMET terbukti paling unggul dibanding metrik lainnya karena menggunakan representasi neural yang dilatih dari penilaian manusia, sehingga lebih mampu menangkap adequacy dan fluency secara semantik. Selain itu, metrik berbasis LLM seperti GEMBA dan EAPrompt juga mulai digunakan untuk memberikan evaluasi yang lebih kontekstual dan mendekati penilaian manusia.

d. Kesimpulan

Menjawab ketiga permasalahan dalam poin b :

1. LLM terbukti mampu menghasilkan terjemahan yang lebih akurat dan fasih melalui kombinasi teknik prompt engineering, fine-tuning, dan in-context learning. Hal ini dibuktikan dengan perbandingan model pada dataset FLORES, di mana GPT-4 pada pasangan bahasa Inggris-Jerman mencatatkan skor BLEU sebesar 35,38 dan COMET sebesar 87,44, mengungguli model-model lain seperti BLOOMZ-7B yang hanya mencapai BLEU 20,63 dan COMET 74,16. Selain itu, pada dataset Wiki, metode INT-4 quantized GLM-130B menunjukkan performa yang seimbang dan konsisten di berbagai metrik evaluasi, mengindikasikan bahwa kombinasi strategi yang tepat mampu menghasilkan terjemahan berkualitas tinggi.
2. LLM mengatasi ambiguitas leksikal, struktural, maupun morfologis melalui mekanisme attention yang mampu menangkap informasi kontekstual secara menyeluruh. Berdasarkan analisis komparatif pada Tabel 3, DeepL mencatatkan skor BLEU tertinggi untuk pasangan bahasa Inggris-Jerman sebesar 76,64, jauh melampaui model seperti OPUS yang hanya mencapai 27,04 dan mBART50 sebesar 26,43, menunjukkan bahwa model dengan kemampuan kontekstual yang lebih kuat mampu menyelesaikan ambiguitas dengan lebih baik. Selain itu, model LLaMA 65B dengan 5-shot prompting mencatatkan skor BLEU 63,47 untuk pasangan Inggris-Italia dan 66,31 untuk Inggris-Rusia, mengungguli konfigurasi model yang lebih kecil seperti LLaMA 7B dengan 0-shot prompting yang hanya mencapai 45,24 dan 55,23 secara berturut-turut, membuktikan bahwa model yang lebih besar dengan lebih banyak contoh prompting mampu menangani ambiguitas pada pasangan bahasa yang kompleks secara lebih efektif.
3. integrasi informasi visual dan tekstual yang difasilitasi oleh arsitektur transformer terbukti menghasilkan terjemahan yang lebih akurat secara kontekstual. Berdasarkan Tabel 7, model ERNIE-UniX2 pada dataset Multi30k untuk pasangan bahasa Inggris-Jerman mencatatkan skor BLEU tertinggi sebesar 49,3, jauh melampaui model-model lain seperti VAG-NMT yang hanya mencapai 31,6 dan DCCN sebesar 39,7. Sementara itu, model ViTA pada dataset Hindi Visual Genome untuk pasangan Inggris-Hindi mencatatkan skor BLEU sebesar 44,6, membuktikan bahwa penggabungan modalitas visual dan teks memberikan kontribusi nyata dan terukur terhadap peningkatan kualitas terjemahan secara keseluruhan.

Jurnal 4

a. Latar Belakang

Di dunia e-commerce yang terus berkembang, memahami kepuasan pelanggan adalah kunci agar bisnis tetap kompetitif. Setiap ulasan dan rating pelanggan merupakan sumber informasi kaya yang dapat mengungkap apa yang paling dihargai konsumen dan di mana mereka mengalami kesulitan. Seiring dengan berkembangnya bisnis maka pelanggan akan meningkat berbanding lurus dengan peningkatan umpan balik yang harus dianalisis sehingga, metode analisis umpan balik tradisional secara manual sudah di relevan karena memakan waktu lama, padat karya, dan sangat subjektif karena adanya bias manusia. Dengan berkembangnya teknologi pembelajaran mesin (*machine learning*) dapat diintegrasikan menjadi solusi. Namun banyak model yang ada hanya mampu menilai sentimen umum, masih gagal dalam Aspect-Based Sentiment Analysis (ABSA). Seperti ketika ulasan mengandung sentimen campuran, misalnya pujian untuk pengiriman tetapi memberi keluhan untuk kualitas produk atau aspek implisit yaitu sentimen yang tersirat tanpa pernyataan eksplisit. Inilah celah yang menjadi landasan penelitian ini berasumsi di perlunya model yang canggih untuk menangkap nuansa kompleks tersebut.

b. Permasalahan

Masalah utama yang diidentifikasi adalah fragmentasi dalam riset analitik umpan balik e-commerce. Karena sulit beradaptasi dengan beragam ulasan, tidakmampu mendeteksi opini implisit, sulit untuk melacak bagaimana model mengambil keputusan. Berdasarkan celah ini, penulis merumuskan dua pertanyaan riset :

1. Bagaimana model berbasis transformer dan large language models (LLM) dapat diintegrasikan ke dalam sebuah alur kerja (pipeline) ujung-ke-ujung yang terpadu dan otomatis untuk ABSA dalam e-commerce?
2. Sejauh mana arsitektur multi-model meningkatkan akurasi, interpretabilitas, dan skalabilitas deteksi sentimen dan aspek dibandingkan dengan pendekatan model tunggal?

c. Metode/Teori

Peneliti membangun sebuah pipeline komprehensif yang terdiri dari beberapa model dan menetapkan 14 aspek kunci yang membentuk pengalaman e-commerce, seperti Pengiriman, Kepercayaan, Kualitas Barang, Harga, Layanan Pelanggan, Proses Pengembalian, hingga Pengalaman Aplikasi. Dengan arsitektur sebagai berikut :

Sumber Data: Data dikumpulkan dari platform ulasan Trustpilot, terdiri dari ribuan ulasan berbahasa Inggris dari lima toko ritel online-only. Dua dataset dianotasi secara manual: satu untuk ekstraksi aspek (menggunakan IOB tagging) dan satu lagi untuk ABSA (14 aspek yang telah ditentukan, sentimen terkait, dan sentimen keseluruhan).

Arsitektur Pipeline (Alur Kerja Multi-Model):

1. LLM untuk Augmentasi Data: Model TinyPixel/Llama-2-7B yang telah disetting-ulang (fine-tuned) menggunakan teknik Soft Prompt Tuning (SFT)

dengan kuantisasi, digunakan untuk menghasilkan data sintetis beranotasi. Ini secara khusus menarget aspek-aspek yang jarang muncul dalam data asli untuk menyeimbangkan dataset dan meningkatkan performa model di semua kategori.

2. Model Deteksi Aspek (BERT_Review): Model BERT (Bidirectional Encoder Representations from Transformers) yang telah melalui proses post-training khusus untuk tugas Review Reading Comprehension (RRC) sangat peka terhadap struktur kalimat dalam domain luas. Sehingga model ini khusus bertugas mengidentifikasi aspek-aspek yang disebutkan secara eksplisit dalam teks. Pemanfaatan arsitektur transformer encoder untuk membaca teks secara dua arah (kiri ke kanan dan sebaliknya), sehingga memahami konteks setiap kata dengan sangat presisi.
3. Model Deteksi Aspek (LLM): Model Llama-2-7B yang lain di-fine-tuned untuk mendeteksi aspek, termasuk aspek implisit yang tidak bisa ditangkap oleh BERT. Dilatih untuk memahami maksud kalimat. Fine-tuning pada dataset ABSA menjadikannya mampu menghubungkan kata sifat, keluhan, atau pujian dengan aspek yang relevan. Gabungan dari output BERT dan LLM ini (union) menjadi set aspek final, memaksimalkan cakupan.
4. Model Analisis Sentimen Berbasis Aspek (ABSA): Pendekatan dua jalur digunakan:
 - a. RoBERTa (A Robustly Optimized BERT Pretraining Approach) adalah evolusi dari BERT dengan optimasi parameter dan data pelatihan yang jauh lebih besar. Model transformer yang sangat cepat dan akurat untuk mengklasifikasikan sentimen setiap aspek pada ulasan yang tidak memiliki sentimen campuran, karena akurasi menurun drastis pada ulasan yang mencampurkan sentimen positif dan negatif pada aspek yang berbeda dalam satu kalimat.
 - b. LLM (Llama-2-7B): Model yang sama untuk ABSA digunakan ketika sentimen keseluruhan ulasan campuran (mixed), karena unggul dalam menangani kontradiksi dalam satu kalimat. Hanya digunakan ketika model pendeteksi sentimen keseluruhan dan memutuskan bahwa sebuah ulasan memiliki sentimen campuran (Mixed)
5. Model Analisis Sentimen Keseluruhan (RoBERTa): Model RoBERTa lain digunakan untuk memprediksi sentimen umum dari ulasan (Positif, Negatif, Campuran). Model RoBERTa yang di-fine-tune secara terpisah pada tugas klasifikasi sentimen dokumen dengan membaca keseluruhan teks ulasan dan memutuskan apakah pengalaman pelanggan secara umum bernada Positif, Negatif, atau Campuran (Mixed).

d. Kesimpulan

Berdasarkan hasil pembahasan peneliti menggunakan pengembangan bertahap untuk melatih LLM sehingga menghasilkan data sintetis bertarget pada aspek yang

kurang terwakili. Kelemahan model transformer standar diatasi dengan menggabungkannya dengan LLM yang memiliki pemahaman kontekstual lebih dalam, menggunakan strategi "union" untuk menggabungkan kekuatan keduanya. Mengatasi sentimen campuran dengan arsitektur routing cerdas menggunakan model RoBERTa untuk kasus sederhana dan model LLM hanya untuk kasus rumit. Integrasikan seluruh model menjadi sebuah pipeline tunggal yang menerima teks ulasan mentah dan menghasilkan output terstruktur. Menjawab permasalahan poin b :

1. Penelitian ini berhasil mendemonstrasikan bahwa mengintegrasikan model berbasis transformer BERT dan RoBERTa dengan Large Language Model (Llama-2-7B) dalam satu pipeline terpadu secara signifikan meningkatkan otomatisasi dan kedalaman analisis. Arsitektur ini memungkinkan deteksi aspek eksplisit dan implisit.
2. Arsitektur multi-model secara fundamental lebih unggul dibandingkan pendekatan model tunggal. Keunggulannya mencakup peningkatan akurasi, kemampuan mendeteksi aspek yang beragam dan implisit, interpretabilitas yang lebih baik berkat peran yang jelas dari setiap modul, dan skalabilitas dalam memproses volume data besar. Model ini berhasil mencapai F1-score sebesar 89% untuk aspek dan 91% untuk sentimen.

Jurnal 5

a. Latar Belakang

Transisi global menuju ekonomi hijau dan digital menciptakan kebutuhan material baru yang belum pernah terjadi sebelumnya. Beberapa elemen kritis — termasuk logam grup Platinum, Rare Earth, Gallium, dan Germanium — sudah menghadapi risiko pasokan yang signifikan. Salah satu strategi yang menjanjikan adalah pengembangan material substitusi baru dalam bentuk paduan tingkat lanjut, khususnya High Entropy Alloys (HEAs) atau Paduan Entropi Tinggi. HEAs menunjukkan potensi besar dalam berbagai aplikasi, termasuk sifat mekanik yang luar biasa dan performa katalitik yang tinggi. Namun, jumlah kemungkinan kombinasi komposisi paduan sangat besar (astronomically large), sehingga pendekatan tradisional trial-and-error menjadi sangat tidak efisien.

Artificial Intelligence (AI) dipandang sebagai solusi untuk mempercepat proses penemuan material baru ini. Akan tetapi, efektivitas AI sangat bergantung pada ketersediaan database material yang ekstensif dan andal. Hingga saat ini, sudah ada alat seperti ChemDataExtractor yang mampu mengekstrak sifat-sifat fisik dari puluhan hingga ratusan ribu paper ilmiah secara otomatis. Namun, untuk mendukung penemuan material berbasis AI secara lebih komprehensif, dibutuhkan deskriptor tambahan dan proses ekstraksi properti yang lebih lengkap.

b. Permasalahan

Terdapat beberapa permasalahan utama yang diidentifikasi oleh peneliti:

1. Keterbatasan database manual: Database yang dikurasi secara manual oleh manusia memang mengandung informasi yang sangat andal karena berasal dari hasil eksperimen yang telah divalidasi (peer-reviewed). Namun, cakupannya sangat terbatas dan proses pengembangannya memakan waktu lama.
2. Ketidakakuratan database komputasi: Database komputasi seperti Materials Project menawarkan cakupan yang jauh lebih luas, tetapi prediksi teoritisnya sering kali menyimpang dari hasil eksperimen nyata, sehingga menimbulkan pertanyaan soal aplikabilitasnya di dunia nyata.
3. Volume literatur yang masif: Berdasarkan data Web of Science (WoS), terdapat 22.745 dokumen berbahasa Inggris tentang HEAs yang telah dipublikasikan sejak tahun 2004. Menganalisis seluruh literatur ini secara manual untuk mengekstrak data komposisi, fase kristalografi, dan metode sintesis merupakan tantangan yang sangat besar.
4. Kebutuhan ekstraksi data otomatis yang komprehensif: Diperlukan pendekatan otomatis yang dapat mengekstrak tidak hanya sifat fisik sederhana, melainkan juga informasi kompleks seperti identifikasi fase, kristalografi, komposisi kimia, metode fabrikasi, dan parameter pemodelan teoritis dari ribuan artikel ilmiah secara bersamaan.

c. Metode/Teori

1. Akuisisi Data

Dari total 22.745 dokumen tentang HEA di Web of Science, peneliti mengumpulkan 4.625 artikel ilmiah yang dapat diakses melalui API penerbit (Elsevier, Springer Nature, dan Royal Society of Chemistry). Artikel-artikel ini dikonversi ke format yang dapat diproses oleh LLM (XML dan Markdown).

2. Arsitektur Large Language Model (LLM)

Peneliti menggunakan model LLM dengan arsitektur hibrida mutakhir bernama Jamba 1-5 Large, yang memiliki karakteristik:

- Total parameter: 398 Miliar
- Parameter aktif: 94 Miliar (menggunakan prinsip Mixture-of-Experts / MoE)
- Arsitektur: Gabungan Transformer + Mamba (sequence modeling waktu-linear)
- Keunggulan: Mampu memproses seluruh isi artikel ilmiah dalam satu context window tunggal, sehingga menjaga konsistensi ekstraksi informasi di seluruh dokumen.

3. Prompt Engineering dan Manajemen Konteks

Peneliti menerapkan teknik Iterative Chain-of-Thought Prompting, di mana setiap interaksi berikutnya dengan LLM menggabungkan konteks kumulatif dari seluruh pertukaran sebelumnya. Pipeline ini terdiri dari 5 prompt berurutan yang masing-masing dirancang untuk mengidentifikasi komponen kunci yang berbeda:

- Prompt 1: Mengidentifikasi paduan (alloy) yang ada dalam artikel
 - Prompt 2: Menentukan fase kristalografi dari setiap paduan
 - Prompt 3: Mengecek jenis studi (eksperimental atau teoritis)
 - Prompt 4: Memeriksa keberadaan struktur yang terurut sebagian (partially ordered)
 - Prompt 5: Membuat struktur JSON komprehensif dari seluruh hasil ekstraksi
4. Validasi Teknis
- Validasi dilakukan oleh pakar domain (ahli material dan metalurgi) yang membuat referensi jawaban akurat untuk 50 publikasi yang dipilih secara acak.
 - Digunakan dua metrik evaluasi: extraction score (akurasi ekstraksi informasi oleh LLM) dan parsing score (kesesuaian output dengan skema database).
 - Sistem penilaian menggunakan skala biner (0 atau 1) dan skala bertingkat (0, 0.5, 1).

d. Kesimpulan

Penelitian ini berhasil membuktikan bahwa Large Language Model (LLM), khususnya model hibrida Jamba 1-5 Large yang menggabungkan arsitektur Transformer dan Mamba dengan mekanisme Mixture-of-Experts (MoE), dapat digunakan secara efektif untuk mengekstrak data ilmiah secara otomatis dari literatur dalam skala besar. Dengan memproses 4.625 artikel ilmiah tentang High Entropy Alloys (HEAs) melalui pipeline berbasis prompt engineering iteratif (chain-of-thought), peneliti berhasil mengidentifikasi dan mengkarakterisasi sebanyak 12.427 paduan entropi tinggi yang berbeda. Tingkat akurasi ekstraksi yang dicapai cukup tinggi, yaitu 94,3% untuk identifikasi komposisi kimia dan 78,7% untuk identifikasi fase kristalografi.

Dari hasil ekstraksi tersebut, ditemukan bahwa struktur kristal FCC (face-centered cubic) mendominasi paduan HEA fase tunggal dengan proporsi 58,8%, diikuti oleh BCC (body-centered cubic) sebesar 29,2%, sementara HCP (hexagonal close-packed) hanya mencakup 1,7%. Dalam hal metode fabrikasi, teknik peleburan (melting) menjadi yang paling umum digunakan (69%), dengan arc melting sebagai metode terpopuler. Elemen-elemen yang paling sering digunakan dalam desain HEA adalah Ni (69,8%), Cr (68,9%), Fe (65,5%), Co (62,5%), dan Al (36,6%), yang mencerminkan fokus penelitian pada komposisi di sekitar paduan Cantor (CoNiCrFeMn).

Kontribusi utama dari penelitian ini adalah dua hal: pertama, terciptanya dataset HEA berskala besar yang diekstrak secara otomatis dan tersedia secara terbuka melalui Mendeley Data; kedua, metodologi ekstraksi berbasis LLM yang dapat direplikasi dan diadaptasi untuk domain material lainnya di masa depan. Meskipun terdapat penurunan akurasi sekitar 5–10% pada tahap parsing dari format JSON ke tabel relasional, pendekatan ini tetap menunjukkan bahwa otomatisasi berbasis LLM merupakan solusi yang menjanjikan untuk mengatasi keterbatasan pembuatan database material secara manual maupun komputasi konvensional.

DAFTAR PUSTAKA

- Chizhevskiy, V., Marković, G., Benrazzouq, S.-E., Cvelbar, U., Nominé, A., & Zavašnik, J. (2026). *High entropy alloys database generated with large language model*. Scientific Data, 13(1), 612. <https://doi.org/10.1038/s41597-026-06930-z>
- Davoodi, L., Mezei, J., Nikou, S., & Espinosa-Leal, L. (2026). Automating customer feedback analysis in E-commerce: A multi-Model approach. Expert Systems with Applications, 306, 130865. <https://doi.org/10.1016/j.eswa.2025.130865>
- Sarim, M., Masood, F., Maheshwari, M., Faridi, A. R., & Shamsan, A. H. (2025). *Generating reliable software project task flows using large language models through prompt engineering and robust evaluation*. Scientific Reports, 15, 35194. <https://doi.org/10.1038/s41598-025-19170-9>
- Sivamayilvelan, K., Rajasekar, E., Vairavasundaram, S., Balachandran, S., Kotecha, K., & Kulkarni, A. (2026). Building an effective chatbot for optimizing the debt collection process through large language models. *Journal of Big Data*. <https://doi.org/10.1186/s40537-025-01351-y>
- Suram, P., Banik, D., & Sharma, A. K. (2026). *Large language model based machine translation for universal multilingual understanding and translation quality enhancement*. Discover Computing. <https://doi.org/10.1007/s10791-026-10027-x>

LAMPIRAN


Lampiran 1 Bukti Jurnal 1 Terindeks Scopus

Article • Open access

Building an effective chatbot for optimizing the debt collection process through large language models

Sivamayilvelan K.,
Rajasekar E.,
Vairavasundaram S.,
... Kotecha K.,Kulkarni A.

Journal of Big Data, 2026
13(1), 16




Lampiran 2 Bukti Jurnal 2 Terindeks Scopus

Article • Open access

Generating reliable software project task flows using large language models through prompt engineering and robust evaluation

Sarim M.,Masood F.,
Maheshwari M.,Faridi A.R.,
Shamsan A.H.

Scientific Reports, 2025
15(1), 35194




Lampiran 3 Bukti Jurnal 3 Terindeks Scopus

Review • [Open access](#)

Large language model based machine translation for universal multilingual understanding and translation quality enhancement

[Suram P., Banik D.,
Sharma A.K.](#)

[Discover Computing](#), 2026
29(1), 217




Lampiran 4 Bukti Jurnal 4 Terindeks Scopus

Article • [Open access](#)

Automating customer feedback analysis in E-commerce: A multi-Model approach

[Davoodi L., Mezei J.,
Nikou S., Espinosa-Leal L.](#)

[Expert Systems with Applications](#), 2026
, 306, 130865



Lampiran 5 Bukti Jurnal 5 Terindeks Scopus

Article • Open access
High Entropy Alloys Database generated with Large Language Model
Chizhevskiy V.,Markovic G., Scientific Data, 13(1), 2026 0
Benrazzouq S.-E., 612
... Nomine A.,Zavasnik J].

Show abstract View at Publisher Related documents

Scientific Data

United Kingdom | Universities and research institutions | Media Ranking

Country

United Kingdom



Subject Area and Category

Computer Science

- Computer Science Applications
- Information Systems

Decision Sciences

- Statistics, Probability and Uncertainty

Mathematics

- Statistics and Probability

Social Sciences

- Education
- Library and Information Sciences

Publisher

Nature Research

SJR 2025

1.907

Q1

H-Index

165

Lampiran 6 Roadmap Pusdi

Pusat Studi Kecerdasan Artifisial dan Teknologi Digital

Rumusan Topik Penelitian

 Industrial 4.0 and Society 5.0 Implementation	 Smart City	 Digital Twin	 Large Language Model (LLM)	 Healthcare Technology
 IT Governance, Infrastructure Security and Digital Transformation	 Sport Technology and Sport Computing	 Semiconductor, Telecommunication, Embedded System, and Edge Computing	 Multimedia Computing	 AI and Digital Technology Education and Industry